

СТАТИСТИКА БОЛЬШИХ ДАННЫХ

Лекция 11. Предобработка данных.
Анализ временных рядов. Часть 3



Метод Прони



Барон Гаспар де Прони
(1755—1839)

Метод Прони позволяет аппроксимировать последовательность комплексных данных x_1, \dots, x_n моделью, состоящей из m затухающих комплексных экспонент:

$$x_k = \sum_{i=0}^m A_i \exp(-\lambda_i \Delta t k + j(\omega_i \Delta t k + \varphi_i)), \quad (1)$$
$$k = 1, 2, \dots, n.$$

Здесь m — модальная глубина модели, $m \leq n/2$, A_i — амплитуда; ω_i — частота; φ_i — начальная фаза; λ_i — коэффициент затухания; Δt — период дискретизации сигнала; k — номер отсчета; n — число отсчетов сигнала, j — мнимая единица.

Формула Эйлера

$$\exp(\lambda t + j\varphi t) = \exp(\lambda t) (\cos \varphi t + j \sin \varphi t)$$



Метод Прони

Апроксимация вида (1) можно представить в виде следующего полинома:

$$(2) \quad x_k = \sum_{i=1}^m h_i z_i^{k-1}, \quad k = 1, 2, \dots, n, \quad \text{где } h_i = A_i \exp(j\varphi_i), \quad z_i = \exp[(\lambda_i + 2\pi j \omega_i)\Delta t].$$

Метод Прони основан на том, что коэффициенты a_k характеристического полинома

$$P(z) = \prod_{i=1}^m (z - z_i) = z^m + a_1 z^{m-1} + \dots + a_{m-1} z + a_m$$

корни которого равны z_i , удовлетворяют системе линейных уравнений

$$\sum_{k=1}^m a_k x_{i-k} = -x_i, \quad i = m+1, m+2, \dots, n. \quad (3)$$



Метод Прони

Три этапа процедуры Прони:

1. Решается система (3) линейных уравнений: $\sum_{k=1}^m a_k x_{i-k} = -x_i$ относительно коэффициентов a_1, a_2, \dots, a_m характеристического полинома $P(z)$.
2. Вычисляются корни z_1, z_2, \dots, z_m полинома $P(z)$, по которым находятся коэффициенты затухания λ_k и частоты ω_k :

$$\lambda_k = \frac{\ln|z_k|}{\Delta t}, \quad \omega_k = \frac{1}{2\pi\Delta t} \tan^{-1} \frac{\text{Im}(z_k)}{\text{Re}(z_k)}.$$


3. Решается система (2) линейных уравнений $x_k = \sum_{i=1}^m h_i z_i^{k-1}$ относительно комплексных амплитуд h_k . вещественные амплитуды A_k и фазы φ_k равны

$$A_k = |h_k|, \quad \varphi_k = \tan^{-1} \frac{\text{Im}(h_k)}{\text{Re}(h_k)}.$$

При $n > 2m$ системы (2) и (3) будут переопределеными. Для их решения применяют метод наименьших квадратов.



Метод Прони.Пример



5

Показатель Херста

Многие изучаемые системы (солнечные пятна, среднегодовых значений выпадения осадков, финансовые рынки...) не являются нормально-распределенными или близкими к ней.

Для анализа таких систем Херст предложил новую статистику – показатель Херста (H). Данный метод позволяет различить случайный и фрактальный временные ряды, а также делать выводы о наличии непериодических циклов, долговременной памяти и т.д.



Гарольд Эдвин Хёрст
(1880—1978)



Показатель Херста



Броуновское движение - хаотическое движение микрочастиц, взвешенных в жидкости или газе (Броун, 1827).

Среднеквадратичное смещение частицы пропорционально корню квадратному из времени наблюдения (Формула Эйнштейна-Смолуховского):

$$\bar{X} = Ct^{0.5}.$$

В теории случайных процессов используется **Винеровский процесс** W_t как **математическая модель броуновского движения** (случайного блуждания с непрерывным временем).




Рис. Симуляция броуновского движения.






Определение винеровского процесса.

1. $W_0 = 0$
2. W_t — процесс с независимыми приращениями.
3. Разность $W_t - W_s$ распределена по нормальному закону $N(0, \sigma^2(t - s))$.

Винеровский процесс масштабно инвариантен или самоподобен. Если W_t — винеровский процесс, и $c > 0$, то $V_t = \frac{1}{\sqrt{c}} W_{ct}$ также является винеровским процессом.

Демонстрация масштабной
инвариантности
винеровского процесса:





Показатель Херста H

Показатель Херста H определяется в терминах асимптотического поведения временного ряда следующим образом:

$$E\left(\frac{R(n)}{s(n)}\right) = Cn^H,$$

где $R(n)$ — размах накопленных отклонений первых n значений от среднего значения ряда, $s(n)$ — стандартное отклонение; n — величина промежутка времени (количество точек в отрезке временного ряда), C — константа.

Размах $R(n)$: $R(n) = \max_{m=1,n} X(m, n) - \min_{m=1,n} X(m, n), \quad 1 \leq m \leq n.$

$x(t)$ случайная величина, $x_i = x(t_i)$, n - длина выборки, \bar{x} — ее среднее,

$s(n) = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$ - стандартное отклонение, $X(m, n) = \sum_{i=1}^m (x_i - \bar{x})$ — накопившееся отклонение значений x_i от ее среднего значения за время m .





Свойства показателя Херста

Для случайного процесса с независимыми приращениями и конечной дисперсией было строго доказано (Feller W. The asymptotic distribution of the range of sums of independent variables // Ann. Math. Statist. 1951. V. 22), что показатель **H равен 0,5**.

Имеются три различных классификации для показателя Херста:

1) **$H \approx 0.5$**

Указывает на случайный ряд. События случайны и некоррелированы. Настоящее не влияет на будущее. Функция плотности вероятности может быть нормальной кривой, однако это не обязательное условие. R/S-анализ может классифицировать произвольный ряд, безотносительно к тому, какой вид распределения ему соответствует.



2) $0.5 < H < 1.0$

Имеем **персистентные**, или сохраняющие тренд ряды. Если ряд возрастает (убывает) в предыдущий период, то вероятно, что он будет сохранять эту тенденцию какое-то время в будущем. Тренды очевидны. Трендоустойчивость поведения или сила персистентности, увеличивается при приближении H к 1. Чем ближе H к 0.5, тем более зашумлен ряд и тем менее выражен его тренд.

Персистентный ряд – это обобщенное броуновское движение, или смешанные случайные блуждания. Сила этого смещения зависит от того, насколько H больше 0.5. Персистентные временные ряды являются собой более интересный класс, так как оказалось, что они не только в изобилии обнаруживаются в природе, – это открытие принадлежит Херсту, – но и свойственны рынкам капитала.





Свойства показателя Херста

3) $0 \leq H < 0.5$

Данный диапазон соответствует **антиперсистентным**. Такой тип системы часто называют – «возврат к среднему». Если система демонстрирует рост в предыдущий период, то скорее всего, в следующем периоде начнется спад. И наоборот, если шло снижение, то вероятен близкий подъем. Устойчивость такого антиперсистентного поведения зависит от того, насколько H близко к нулю. Такой ряд более изменчив, или волатилен, чем ряд случайный, так как состоит из частых реверсов спад-подъем. Несмотря на широкое распространение концепции возврата к среднему в экономической и финансовой литературе, до сих пор было найдено мало антиперсистентных рядов.

Вычисление показателя Херста



1. Для первые n членов исходного ряда рассчитаем среднее значение и стандартное отклонение:

$$E(n) = \frac{1}{n} \sum_{k=1}^n x_k, s(n) = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - E(n))^2}.$$


2. Отклонения от среднего значения: $X(k, n) = \sum_{i=1}^k (x_i - E(n))$.

3. Размах: $R(n) = \max_{k=1,n} X(k, n) - \min_{k=1,n} X(k, n)$. Делим $R(n)$ на $s(n)$

4. Увеличиваем n повторяем шаги 1-3 и строим две выборки значений:


$$y(n) = \ln(R(n)/s(n)) \text{ и } z(n) = \ln(n)$$

5. Находим регрессию вида: $y = Hz + c$. Коэффициент H – оценка показателя Херста.






Пример ряда годовых температур СПб



Вычисление показателя Херста для
начала ряда среднегодовых температур
Спб (первые 40 точек, 1753-1793г).
H=0.737




Вычисление показателя Херста для
середины ряда среднегодовых температур
Спб (точки с 120 по 170, 1873-1923г).
H=0.554






Пример ряда годовых температур СПб



Вычисление показателя Херста для ряда среднегодовых температур Спб точки с 180 по 220, 1933-1973г). **H=0.462**



Вычисление показателя Херста для конца ряда среднегодовых температур Спб (последние 40 точек, 1976-2016г). **H=0.932**

Пример ряда годовых температур СПб





Контрольные вопросы и задания

1. Составить на языке R программу разложения ряда по методу Прони. Для ее проверки сгенерировать модельный ряд $x_i = \sum_{k=1}^3 k \exp\left(-\frac{hi}{k}\right) \cos\left(4\pi k h i + \frac{\pi}{k}\right)$, $i = 1, \dots, 200$, $h = 0.02$ и применить к нему метод Прони.
2. Найти в интернете данные по среднесуточным температурам за два года вашего населенного пункта и провести их анализ на наличие тренда и сезонных колебаний.