

СТАТИСТИКА БОЛЬШИХ ДАННЫХ

Лекция 18. Регрессионный анализ. Часть 2




Зависимость среднегодовых температур СПб от времени

```
> f<-scan("SPB.txt",what="numeric")
Read 264 items
> y<-as.numeric(f)
> n<-length(y)
> x<-c(1753:(1752+n))
> data1<-data.frame(year=x,temperature=y)
> M<-lm(y~x,data=data1)
> summary(M)
Call:
lm(formula = y ~ x, data = data1)

Residuals:
    Min      1Q      Median      3Q      Max 
-3.00281 -0.63548  0.05369  0.86254  2.54936 

Coefficients:
            Estimate      Std. Error      t value      Pr(>|t|)    
(Intercept) -1.339e+01 1.623e+00   -8.252 7.65e-15 ***  
x           9.367e-03 8.606e-04   10.884 < 2e-16 ***  
Residual standard error: 1.066 on 262 degrees of freedom
Multiple R-squared: 0.3114,  Adjusted R-squared: 0.3087
```

Зависимость среднегодовых температур СПб от времени



Нелинейные модели

В общем случае рассматривается регрессионная модель вида:

$$y_i = f(x_i, \beta) + e_i, \quad i = 1, \dots, n; \quad \beta = (\beta_1, \dots, \beta_l).$$

Задача нахождения значений векторного параметра β сводится к нелинейной задаче МНК в виде задачи нелинейного программирования:

$$RSS = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - f(x_i, \beta))^2 \rightarrow \min_{\beta}.$$

Решение таких задач рассматривается в курсе по методам оптимизации.



Нелинейные модели

Нелинейные регрессионные модели, сводящиеся к простой линейной регрессии при помощи замены переменных.

1. Модели, в которых преобразуются только факторы (замена переменной фактора).

Пусть коэффициенты β входят линейно, а фактор X – нелинейно:

$$Y = \beta_0 + \beta_1 F(X) + e,$$

Положив $Z = F(X)$, мы приходим к уравнению линейной регрессии

$$Y = \beta_0 + \beta_1 Z + e.$$

1) $Y = \beta_0 + \beta_1(1/X) + e; \quad Z = 1/X.$

2) $Y = \beta_0 + \beta_1 \ln X + e; \quad Z = \ln X.$

3) $Y = \beta_0 + \beta_1 X^{1/2} + e; \quad Z = X^{1/2}.$

Примеры:





Нелинейные модели

2. Нелинейные модели, в которых наряду с факторами преобразуется и отклик

Мультипликативная модель:

$$Y = \alpha X^\gamma \varepsilon,$$

α, γ – неизвестные параметры, ε – мультипликативная случайная ошибка, распределенная на положительной полуоси с математическим ожиданием, равным единице и конечной дисперсией.

Логарифмирование исходного уравнения :

$$\ln Y = \ln \alpha + \gamma \ln X + \ln \varepsilon \quad \text{или} \quad V = \beta_0 + \beta_1 Z + e,$$

где $V = \ln Y, Z = \ln X, \beta_0 = \ln \alpha, \beta_1 = \gamma, e = \ln \varepsilon$.



Нелинейные модели

Экспоненциальная модель:

$$Y = \alpha \exp(\gamma X) \varepsilon, \quad \ln Y = \ln \alpha + \gamma X + \ln \varepsilon, \quad V = \beta_0 + \beta_1 Z + e,$$

Здесь $V = \ln Y$, $Z = X$, $\beta_0 = \ln \alpha$, $\beta_1 = \gamma$, $e = \ln \varepsilon$

Обратная модель:

$$Y = \frac{1}{\beta_0 + \beta_1 F(X) + e}, \quad \frac{1}{Y} = \beta_0 + \beta_1 F(X) + e, \quad V = 1/Y$$

Обратная экспоненциальная модель:


$$Y = \frac{1}{1 + \alpha \exp(\beta_1 X + e)}, \quad \ln(1/Y - 1) = \ln \alpha + \beta_1 X + e.$$
$$V = \ln(1/Y - 1)$$



Пример.Расчет показателя Херста

```
1. f<-scan("SPB.txt",what="numeric")
2. y<-as.numeric(f)
3. RS<-vector("numeric",length=31)
4. LN<-vector("numeric",length=31)
5. for (i in 10:40)
6. {
7.   y1<-vector("numeric",length=i)
8.   x<-vector("numeric",length=i)
9.   z<-vector("numeric",length=i)
10.  y1<-y[1:i]
11.  m<-mean(y1)
12.  s<-sd(y1)
13.  x<-y1-m
14.  for (k in 1:i) { Z[k]<-sum(X[1:k]) }
15.  R<-max(Z)-min(Z)
16.  RS[i-9]<-log(R/s)
17.  LN[i-9]<-log(i)
18. }
19. data1<-data.frame(LN,RS)
20. M<-lm(RS~LN,data=data1)
21. H<-M$coefficient[2]
```

Первые 40 точек ряда среднегодовых температур СПб



Контрольные вопросы и задания

1. Составить таблицу сопоставляющую рост и вес взрослых людей например, членов семьи, друзей, членов учебной группы и т.п. (5-10 человек).
2. Без применения программных средств построить модель простой линейной регрессии зависимости веса от роста. Нанести на график исходные точки и линию регрессии.
3. Вычислить суммы квадратов остатков (RSS), стандартной ошибки остатков (RSE) и корреляционное отношение η^2 (R^2). Сделать выводы о степени адекватности линейной модели.
4. Составить таблицу сопоставляющую возраст и вес различных людей на примере членов семьи, родственников и знакомых (10-20 значений). В среде программирования R построить мультиплексную модель нелинейной регрессии зависимости веса от возраста. Нанести на график исходные точки и линию регрессии. Оценить адекватность модели.

