


СТАТИСТИКА БОЛЬШИХ ДАННЫХ

Лекция 21. Методы регуляризации в задаче множественной линейной регрессии. Часть 1



В этой лекции рассматриваются отличные от метода наименьших квадратов подходы к решению задач множественной линейной регрессии и отбору значимых факторов при больших размерностях модели.

- Мотивация и постановка задачи регуляризации
- Методы регуляризации: гребневая и лассо регрессии
- Примеры
- Заключение



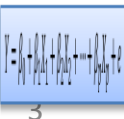
Мотивация и постановка задачи регуляризации


Стандартная линейная модель:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + e$$

В этой лекции мы обсудим модификации обычного критерия наименьших квадратов и методов отбора переменных в целях достижения лучшей точности прогноза, отбора значимых факторов и интерпретируемости модели.

- Если число наблюдений n много больше, чем число переменных p ($n \gg p$), то МНК-оценки имеют малые дисперсии.
- Если $n \approx p$, то тогда растет дисперсия прогноза и уменьшается его точность.
- Если $p > n$, тогда нет единственности МНК-оценок коэффициентов регрессии и МНК неприменим.



$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + e$$



Мотивация и постановка задачи регуляризации

Задача, решение которой не единственно, относится к **некорректным задачам**. Для решения некорректных задач применяются методы регуляризации. Один из таких методов заключается во введении дополнительных слагаемых в целевую функцию МНК.

Отбор значимых факторов. Увеличение числа p переменных модели обычно связано с включением в модель незначимых или зависимых факторов. Методы отбора факторов (прямой, обратный и смешанный отбор) здесь в силу эффекта больших данных ($p > n$) не работают. Желательно предложить метод, который позволил бы в этой ситуации исключать незначимые и лишние факторы.



Мотивация и постановка задачи регуляризации

Интерпретируемость модели. Часто наблюдается, что некоторые переменные множественной линейной регрессии в действительности не связаны с откликом. Удалить эти переменные можно положив значения соответствующих коэффициентов регрессии равными нулю.

Существует несколько альтернатив использованию МНК:

- отбор подмножества факторов (Subset Selection)
- сокращение размерности (Dimension Reduction)
- регуляризация (Shrinkage) - гребневая регрессия и метод лассо.

Ниже мы остановимся на методах регуляризации процедуры оценивания по МНК в случае большой размерности модели (случай $p > n$).

Гребневая регрессия

МНК-процедура подгонки оценок $\beta_0, \beta_1, \dots, \beta_p$ минимизирует выражение

$$RSS = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2.$$

Гребневая регрессия получена из МНК введением функции штрафа $\lambda \sum_{j=1}^p \beta_j^2$ на величину коэффициентов β_1, \dots, β_p . В результате решается задача нахождения коэффициентов гребневой (ridge) регрессии $\beta_j^{(r)}$ минимизирующих

$$RSS + \lambda \sum_{j=1}^p \beta_j^2 = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2,$$

где $\lambda > 0$ — штрафной коэффициент.




Гребневая регрессия

Метод представляет собой компромисс между двумя различными критериями. Как и в случае *МНК*, гребневая регрессия нацелена на подгонку к данным, уменьшая величину *RSS*. Однако, стремление к уменьшению штрафной функции обеспечивает сжатие оценок β_j к нулю.

Коэффициент штрафа λ используется для баланса влияния на оценки обоих слагаемых в целевой функции.

- Если $\lambda=0$, то гребневая регрессия совпадает с *МНК*-регрессией.
- При росте λ влияние штрафа растет, а оценки коэффициентов β_j стремятся к нулю.

Заметим, что штраф не накладывается на β_0 , который просто измеряет среднее значение отклика при нулевых значениях факторов.



Особенности поведения гребневой регрессии

Когда число факторов p приближается к числу наблюдений n , то дисперсия МНК-оценок неограниченно возрастает. Далее, если $p > n$, то МНК-оценки будут не единственными, т.е., метод наименьших квадратов в этом случае неприменим.

В рассмотренных случаях ($p \leq n$ и $p > n$) оценки гребневой регрессии в целом будут вполне приемлемыми, уступая в точности оценкам МНК в случае малых p и являясь компромиссом между значениями дисперсии оценок и их смещения в случае больших p – метод гребневой регрессии универсален.

Гребневая регрессия имеет один очевидный недостаток — она всегда включает в себя все p факторов. Штраф $\lambda \sum_j \beta_j^2$ сожмет все коэффициенты но не сделает их равными нулю. Увеличение параметра λ безусловно уменьшит рассеяние оценок коэффициентов регрессии, но никогда не приведет к исключению из модели какой-либо переменной.

Метод лассо (*LASSO -- Least Absolute Shrinkage and Selection Operator*) (Tibshirani, 1996) представляет собой альтернативу гребневой регрессии, которая не имеет указанного недостатка. Коэффициенты лассо $\beta_j^{(L)}$ минимизируют следующую функцию цели с негладким штрафом $\lambda \sum_{j=1}^p |\beta_j|$:

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j| = RSS + \lambda \sum_{j=1}^p |\beta_j| .$$

Метод лассо и гребневая регрессия имеют близкие формализации. Единственное различие состоит в использовании в качестве штрафных функций различных норм, l_2 -норму в гребневой регрессии и l_1 -норму в лассо.

Как и в случае гребневой регрессии, лассо сжимает оценки к нулю. Однако, в случае лассо l_1 -штраф имеет эффект обращения в нуль некоторых коэффициентов регрессии при достаточно большом значении параметра настройки λ . Следовательно, лассо обладает свойством отбора переменных (variable selection).

Модели, сгенерированные на основе лассо, значительно легче интерпретировать, чем модели гребневой регрессии. Можно сказать, что лассо порождает *разреженные модели*, т.е., модели, работающие с некоторым подмножеством множества переменных – подмножество отобранных значимых факторов.

При $\lambda = 0$ лассо дает подгонку по *МНК*.

Когда λ становится достаточно большим, лассо дает нулевую модель, в которой все оценки коэффициентов равны нулю.

Между этими двумя крайними случаями гребневая регрессия и лассо сильно отличаются друг от друга:

- В зависимости от величины λ лассо может генерировать модель с любым числом значимых факторов.
- Напротив, гребневая регрессия включает в себя все факторы, хотя величины оценок коэффициентов при них зависят от λ .

Пример 1

Зададим число и вектор в 10-мерном пространстве: $\beta_0 = 3$; $\beta^* = (1, 0, \dots, 0, -1)$.

Зададим 5 векторов значений факторов размерности $p = 10$:

$$x_k = (x_{k1}, x_{k2}, \dots, x_{kp}), \quad k = 1, \dots, n; \quad n = 5.$$

Вычислим 5 значений отклика: $y_k = \beta_0 + (\beta^*, x_k) + e_k, \quad k = 1, \dots, n.$

e_k — случайная ошибка, распределенная по нормальному закону с нулевым средним.

Задача: оценить вектор β^* и свободный член β_0 по значениям отклика y_k и значениям факторов - векторам x_k .

Это задача множественной линейной регрессии со значениями $n=5$ и $p=10$.

Применим метод гребневой регрессии и метод лассо и сравним их результаты.

Решение задачи оформим в пакете R.

Пример 1


```
1) library(glmnet)
2) p<-10
3) n<-5
4) b<-c(1,0,0,0,0,0,0,0,-1)
5) b0<-3
6) X<-matrix(nrow=n,ncol=p)
7) for (j in 1:p) { for (i in 1:n){X[i,j]<- rnorm(1,0,3)}}
8) X
9)      [,1]      [,2]      [,3]      [,4]      [,5]      [,6]      [,7]      [,8]      [,9]     [,10]
10) [1,] 0.2422478 0.1384479 -1.3618779 -2.637685 0.3566118 -1.0923557 0.7041286 1.35862104 -1.752460 -1.2596165
11) [2,] 0.1466275 2.4573147 -0.4119873 1.460291 -3.1334400 -0.9963586 -2.1645335 -0.38991209 4.388400 4.4265086
12) [3,] -1.2353552 -2.6302537 -3.0084073 2.027529 4.0841774 3.0425508 0.8452573 -5.12048739 -1.269423 4.3189563
13) [4,] 1.8505990 -1.7720798 -0.8919914 -1.873983 0.1038625 0.8889142 -0.1988888 3.13081581 7.217463 -2.0865766
14) [5,] -4.0534826 -5.9159780 1.2720261 -2.523003 0.3691043 -5.1880821 5.4514842 -0.02112122 -2.736105 -0.8520606
15) y<-vector(length=p)
16) for (i in 1:n) {y[i]<- b0+b%*%X[i,]+rnorm(1,0,0.1)}
17) y
18) [1] 4.5284846 -1.3036088 -2.3982667 6.8408026 -0.1077062
19) a<-c(10,1,0.1,0.01,0.001)
```



Пример 1

```
20) ridge.mod=glmnet(X,y,alpha=0,lambda=a)
21) ridge.coef=predict(ridge.mod,type="coefficients",s=a)[0:p+1,]
22) ridge.coef
23) 11 x 5 sparse Matrix of class "dgCMatrix"
24)           1           2           3           4           5
25) (Intercept) 1.652831326 1.685281800 1.67026925 1.670502138 1.670531948
26) V1          0.213407384 0.439418009 0.50301726 0.519477260 0.521188481
27) V2          0.007866803 0.003995102 0.01130088 0.007904743 0.007575406
28) V3         -0.031222534 -0.205675963 -0.28294845 -0.285307916 -0.285562318
29) V4         -0.233254404 -0.480167081 -0.54852311 -0.562772609 -0.564244067
30) V5          0.005367610 0.105569445 0.14346285 0.146823085 0.147173808
31) V6          0.032769200 0.114476865 0.13193654 0.134417817 0.134651713
32) V7         -0.025127596 -0.039494606 -0.03475861 -0.037074943 -0.037311452
33) V8          0.190244607 0.349816483 0.38957493 0.390773062 0.390872074
34) V9          0.062744611 0.088914988 0.08326954 0.080159643 0.079827322
35) V10         -0.200075628 -0.413808885 -0.46082066 -0.462059095 -0.462171648
```

Пример 1




λ	RSS
10	19.02
1	0.8977
0.1	0.01157
0.01	0.0001224
0.001	0.000001916

Пример 1

```
36) lasso.mod=glmnet(X,y,alpha=1,lambda=a)
37) lasso.coef=predict(lasso.mod,type="coefficients",s=a)[0:p+1,]
38) lasso.coef
39) 11 x 5 sparse Matrix of class "dgCMatrix"
40)           1         2         3         4         5
41) (Intercept) 1.511941 2.3122056 2.9448813 2.96581760 2.9594408533
42) V1          .      0.4285897 0.9219040 0.95155657 0.9573593412
43) V2          .          .          .          .          .
44) V3          .          .          .      -0.03464204 -0.0425538183
45) V4          .          .          .          .      -0.0070229625
46) V5          .          .          .          .      0.0000872198
47) V6          .          .          .          .          .
48) V7          .          .          .          .          .
49) V8          .      0.1525901          .          .          .
50) V9          .          .          .          .      -0.0020012179
51) V10         .      -0.5575692 -0.9573958 -0.99406932 -0.9937642554
```


Пример 1



λ	RSS
10	63.34
1	9.474
0.1	0.1041
0.01	0.00206
0.001	0.00004207