


СТАТИСТИКА БОЛЬШИХ ДАННЫХ

Лекция 27. Задача классификации. Часть 2



Байесовская теория классификации

Байесовская теория классификации основана на применении оптимального байесовского классификатора и оценивании плотностей распределения классов по обучающей выборке. Различные методы оценивания плотности порождают большое разнообразие байесовских классификаторов.



Идея метода байесовской классификации

Поиск оптимального алгоритма $a(x)$ сводится к максимизации **апостериорной вероятности** класса y при условии x . Ставится задача определения максимально вероятного класса $y \in Y$, содержащего заданный объект классификации $x \in X$:

$$a(x) = \operatorname{argmax}_{y \in Y} p(y|x)$$

Воспользуемся известной формулой Байеса:

$$a(x) = \operatorname{argmax}_{y \in Y} p(y|x) = \operatorname{argmax}_{y \in Y} \frac{p(x|y)p(y)}{p(x)} = \operatorname{argmax}_{y \in Y} p(x|y)p(y).$$



Байесовские методы классификации

Пусть X - множество объектов, Y - конечное множество имён классов, множество $X \times Y$ является вероятностным пространством с плотностью распределения

$$p(x, y) = P(y)p(x|y).$$

Вероятности появления объектов каждого из классов $P_y = P(y)$ называются **априорными вероятностями классов**.

Плотности распределения $p_y(x) = p(x|y)$ называются **функциями правдоподобия классов**.





Задачи статистической классификации

Задача 1. Имеется обучающая выборка $X^l = (x_i, y_i)_{i=1}^l$ из неизвестного распределения $p(x, y) = P_y p_y(x)$. Требуется построить эмпирические оценки априорных вероятностей \hat{P}_y и функций правдоподобия $\hat{p}_y(x)$ для каждого из классов $y \in Y$.

Задача 2. По известным плотностям распределения $p_y(x)$ и априорным вероятностям P_y всех классов $y \in Y$ построить алгоритм $a(x)$, минимизирующий вероятность ошибочной классификации.

Рассмотрим сначала решение задачи 2.



Решение задачи 2

Функционал среднего риска:

$$R(a) = \sum_{y \in Y} \lambda_y P_y P(a(x) \neq a^*(x)|y)$$

λ_y – плата за неверное распознавание класса
 $v.$

Апостериорная вероятность $P(y|x)$ класса y для объекта x вычисляется по формуле Байеса, если P_y и $p_y(x)$ известны:

$$P(y|x) = \frac{p(x,y)}{p(x)} = \frac{p_y(x)P_y}{\sum_{s \in Y} p_s(x)P_s}.$$





Оптимальное байесовское решающее правило

Байесовское решающее правило. Минимум среднего риска $R(a)$ реализуется на алгоритме:

$$a(x) = \arg \max_{y \in Y} \lambda_y P_y p_y(x)$$

Минимальное значение среднего риска $R(a)$ называется **байесовским риском**.

Если классы равнозначны $\lambda_y = 1$, то байесовское правило называется также **принципом максимума апостериорной вероятности**.

Если классы равновероятны, $P_y = \frac{1}{|Y|}$, то объект x просто относится к классу y с наибольшим значением плотности распределения $p_y(x)$ в точке x .





Задача восстановления плотности распределения

Требуется оценить плотность вероятностного распределения $p(x, y) = P_y p_y(x)$, сгенерировавшего обучающую выборку $(x_i, y_i)_{i=1}^l$

Априорные вероятности классов P_y :

$$\hat{P}_y = \frac{l_y}{l}$$

Задача восстановления плотности

Задано множество из m объектов $X^m = (x_1, \dots, x_m) \subset X$, распределенных согласно неизвестному распределению $p(x)$. **Требуется** построить эмпирическую оценку плотности – функцию $\hat{p}(x)$, приближающую $p(x)$ на всём X .



Наивный байесовский классификатор

Обозначим через $\xi = (\xi_1, \dots, \xi_n)$ произвольный элемент пространства объектов X .

Гипотеза независимости. Признаки ξ_1, \dots, ξ_n являются независимыми случайными величинами.

В этом случае функции правдоподобия классов представимы в виде произведения

$$p_y(\xi) = p_{y1}(\xi_1)p_{y2}(\xi_2) \cdots p_{yn}(\xi_n), \quad y \in Y,$$

где $p_{yj}(\xi_j)$ – плотность распределения значений j -го признака для класса y .



Непараметрическая классификация

Одномерный непрерывный случай ($x \in R$):

$$\hat{p}(x) = \frac{1}{mh} \sum_{i=1}^m K\left(\frac{x - x_i}{h}\right).$$


Многомерный непрерывный случай.

Пусть выполнена гипотеза независимости. Оценка многомерной плотности в точке $\xi = (\xi_1, \dots, \xi_n)$ имеет вид:

$$\hat{p}(\xi) = \prod_{j=1}^n \frac{1}{mh_j} \sum_{i=1}^m K\left(\frac{\xi_j - x_{ji}}{h_j}\right),$$

$x_i = (x_{1i}, \dots, x_{ni})$ – i -ый элемент обучающей выборки X^m

Пример





```
library(klaR)
...
nb<-NaiveBayes(zlab~, data=z)
pre<- predict(nb,ze)$class
...
plot(nb,col = 1:4,lwd=3)
```

Предсказанное

Фактическое


	1	2	3	4
1	51	0	0	0
2	0	50	0	0
3	0	0	50	0
4	0	1	0	48

Пример



Метод опорных векторов (SVM)

$$x \in R^n, y \in Y = \{-1, 1\}.$$



Строим разделяющую гиперплоскость с максимальным зазором:

$$(w^*, x) - b = 0,$$

где w^* – решение задачи оптимизации:

$$(w^*)^2 = \min w^2$$
$$y_i[(w, x_i) - b] \geq 1, \quad i = 1, \dots, l,$$

$(x_i, y_i)_{i=1}^l$ – обучающая выборка

Уравнение классификатора:

$$y = a(x) = \text{sign}((w^*, x) - b)$$

Метод деревьев решений



Метод деревьев решений (**decision tree**) для задачи классификации состоит в делении исходных данных на группы до тех пор, пока не будут получены однородные подмножества.

Идея метода

Метод деревьев решений реализует принцип «рекурсивного разделения». В узлах, начиная с корневого, выбирается признак, значение которого используется для разбиения всех данных на 2 класса. Процесс продолжается до тех пор, пока не выполнится один из критерий остановки:

- Все (или почти все) данные данного узла принадлежат одному классу
- Не осталось признаков, по которым можно построить новое разбиение
- Дерево превысило заранее заданный «предел роста»

Пример



Контрольные вопросы и задания

- 
1. Сформулируйте существенные признаки задач кластеризации и классификации. В чем их сходство и различие?
 2. Классифицируйте методы классификации. Какие из методов классификации можно отнести к статистическим?
 3. Сгенерируйте 3 выборки по 200 элементов из двумерных нормальных распределений с центрами в точках (3,3), (9,2), (9,6) и диагональными ковариационными матрицами с элементами (1.5,1.5), (1,1), (1,1). Решить задачу кластеризации методом k средних. Нарисуйте результирующие графики. Сделайте выводы.
 4. Решить задачу классификации методом k ближайших соседей и наивным байесовским методом, используя решение предыдущей задачи по приведенным образцам в лекции. Построить таблицу результатов.



Заключение

Данный курс лекций включил в себя только основные идеи и подходы применения статистических методов в больших данных. Готовя этот курс, мы, коллектив авторов, многому научились. Мы надеемся, что и для вас он будет полезен и станет отправной точкой для продвижения в области обработки больших данных.

Спасибо за внимание!

